

# Presentación de la materia (y del TP)

## Métodos Numéricos

Departamento de Computación  
Facultad de Ciencias Exactas y Naturales, UBA

March 24, 2024



Bienvenida

## ¿Quiénes somos?

- ▶ Pablo Riera
- ▶ Nicolás Mastropasqua
- ▶ Belén Ticona
- ▶ Sebastián Felgueras
- ▶ Darío Turco

# Organización del Labo

- ▶ Clases:
  - ▶ Viernes de 18hs a 22hs (hay excepciones, ver el calendario)
- ▶ Trabajos Prácticos:
  - ▶ TP1 (Presentación 22/3 - Entrega 21/4 - Reentrega 19/5)
  - ▶ TP2 (Presentación 10/5 - Entrega 2/6 - Reentrega 7/7)
  - ▶ TP3 (Presentación 14/6 - Entrega 30/6 - Reentrega 14/7)
- ▶ Taller presencial grupal:
  - ▶ Desarrollo en clase y defensa en un breve coloquio con algún docente. Presentación y entrega 24/6.

# Motivaciones

- ▶ **Experimentación:** Hacerse preguntas y poder responderlas diseñando experimentos numéricos
- ▶ **Redacción de informes:** Transmitir estas preguntas y sus resultados de forma convincente y clara

Tratar con problemas continuos utilizando métodos que aproximen soluciones numéricas.

A veces, la solución exacta puede no ser viable.

- ▶ Calcular resultados de funciones
- ▶ Resolver sistemas de ecuaciones
- ▶ Computar de autovalores/autovectores
- ▶ Cálculo de integrales
- ▶ Interpolación, extrapolación, regresión
- ▶ Ecuaciones diferenciales
- ▶ Optimización

# Aplicaciones de modelado

- ▶ Machine Learning
- ▶ Modelos físicos, químicos, etc
- ▶ Simulaciones
- ▶ Computación científica en general



## Sobre los informes

- ▶ **Introducción:** explicar los conceptos necesarios para que una persona **no familiarizada con el tema**, por ejemplo un alumno de Computación antes de cursar la materia, pueda entender el núcleo de los modelos matemáticos estudiados en el TP. Es útil dar referencias a la literatura, las teóricas, etc.
- ▶ **Desarrollo:** explicar como hicieron para resolver el problema central, dejándolo en claro las hipótesis del trabajo. Detalles de implementación, demostraciones y metodología en general pueden ser parte de esta sección.

## Sobre los informes

- ▶ **Resultados/Discusión:** pueden ser dos secciones o una sola. Deben incluir los resultados de los experimentos, mostrándolos y explicándolos de una manera comprensible para el lector. Es importante buscar la mejor forma de visualizar lo que se quiere reportar a efectos de facilitar la comprensión del lector.
- ▶ **Conclusiones:** resaltar/enfatizar aquellas hipótesis importantes que fueron validadas con los experimentos y vincularlas con los mismos. Lo que quieren que quede en la mente del lector.

# Sobre el software numérico

## Breve historia del software numérico

- ▶ 1957 - Fortran
- ▶ 1979 - BLAS (Basic Linear Algebra Subprograms)
- ▶ 1984 - MATLAB
- ▶ 1992 - LAPACK (Linear Algebra Package)
- ▶ 1993 - GNU Octave
- ▶ 2000 - R
- ▶ 2005 - NumPy
- ▶ 2006 - EIGEN
- ▶ 2012 - julia

# Introducción al TP

# ¿Qué vamos a hacer?

- ▶ Modelar un fenómeno físico
- ▶ Aplicar métodos numéricos
- ▶ Experimentar y comparar algoritmos

¿Qué objeto matemático vamos a utilizar?

Principalmente...

$$\begin{pmatrix} a_{11} & \dots & a_{1n} \\ a_{21} & \dots & a_{2n} \\ \vdots & \dots & \vdots \\ a_{n1} & \dots & a_{nn} \end{pmatrix}$$

## ¿Para qué lo vamos a usar?

- Resolución de sistemas de ecuaciones lineales

$$\begin{cases} a_{11}x_1 + \dots + a_{1n}x_n = b_1 \\ a_{21}x_1 + \dots + a_{2n}x_n = b_2 \\ \dots + \dots + \dots = \dots \\ a_{n1}x_1 + \dots + a_{nn}x_n = b_n \end{cases}$$

- En forma matricial,  $Ax = b$

# Método esencial

## Eliminación Gaussiana:

- ▶ Forward elimination
- ▶ Backsubstitution

## Variantes:

- ▶ Sin pivoteo
- ▶ Con pivoteo parcial



## Pará, hay más

Si la matriz tiene esta pinta (tridiagonal)

$$\begin{pmatrix} b_1 & c_1 & & & 0 \\ a_2 & b_2 & c_2 & & \\ & a_3 & b_3 & \ddots & \\ & & \ddots & \ddots & c_{n-1} \\ 0 & & & a_n & b_n \end{pmatrix}$$

¿Podemos hacer algo mejor?

**Spoiler:** Sí.

## Cosas importantes

## Antes de empezar, nociones importantes

### Operador Laplaciano ( $\nabla^2$ )

Divergencia del gradiente de una función escalar.

???

# Divergencia

Dado  $F$  un campo vectorial (ej. la velocidad de un fluido) y una superficie  $S$




Figure:  $\text{Div } F$  es una función escalar que mide el flujo saliente en un punto

- Signo de  $\text{Div } F$  y su magnitud indican cuan **source**(+) o **sink** (-) es un punto.
- Más intuición, [acá](#)

## Gradiente

Dado una función  $F$ , su gradiente es un campo vectorial.




Figure: Parados en un punto, indica la dirección de máximo cambio.

Obs:



- Su magnitud es mínima en los extremos y puntos silla.
- Mínimo es punto **source**, máximo es punto **sink**.

# Volvemos, Laplaciano

- ▶ La Divergencia del Gradiente de una función escalar, osea...
- ▶ Mide 'cuanto de mínimo' tiene un punto.
- ▶ Si es positivo en un punto, ' $F$  es más chica allí que el valor promedio de su vecindad'

# El Laplaciano en imágenes

Podemos pensar una imagen de un solo canal como una función  $f : [a, b] \times [a, b] \rightarrow \mathbb{R}$  que determina la intensidad en un punto.





# El Laplaciano en imágenes

- ▶ Los bordes son regiones donde la intensidad cambia muy rápidamente.
- ▶ ¿Qué ocurriría si le aplicamos el Laplaciano ahí? Cambia de signo rápidamente.
- ▶ Esta idea se puede aplicar pero puede dar 'falsos positivos'.

## Detección de borde en 1D




Figure:  $f$  la intensidad en una fila de la imagen, junto con su derivada y el laplaciano

## En 1D, ¿A qué se parece?

La intuición anterior, en 1D, se parece a la derivada segunda (concavidad)...

Sí, de hecho:


- ▶ En 1D, el gradiente es justamente la derivada.
- ▶ En 1D, la divergencia se simplifica a la derivada.

# Laplaciano discreto

- ▶ Restringido al caso 1D, ¿cómo se puede computar?
- ▶ Derivar la función dos veces, ¿no?
- ▶ ¿Cómo derivo? ¿Se puede discretizar la operación?

# Diferencias finitas

Método para aproximar derivadas. Hay varias formas.

- ▶ Forward difference:  $\frac{f(x+h)-f(x)}{\Delta h}$ .
  - ▶ Backward difference:  $\frac{f(x)-f(x-h)}{\Delta h}$ .
- ) = d 

Entonces la operación  $\frac{d^2}{dx^2} u(x) = d$  se puede discretizar como

$$u_{i-1} - 2u_i + u_{i+1} = d_i$$

Siendo  $u$  vector de tamaño  $n$  y tomando  $\Delta h = 1$ ,  $d$  el vector de resultados


## Laplaciano forma final

Era resolver un sistema tridiagonal!

$$\begin{bmatrix} -2 & 1 & & & 0 \\ 1 & -2 & 1 & & \\ & 1 & -2 & \ddots & \\ & & \ddots & \ddots & 1 \\ 0 & & & 1 & -2 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ \vdots \\ u_n \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ d_3 \\ \vdots \\ d_n \end{bmatrix}.$$

## Laplaciano 2D


Se puede extender para el caso 2D y aplicarlo a una imagen digital.



**Figure:** Detección de borde con filtro convolucional laplaciano. El 0 se mapea a 128

## Laplaciano 2D

Podemos plotear el laplaciano en alguna fila de la luna:



Notar el salto bien marcado del borde izquierdo y derecho





## El problema

# El problema a resolver

**¿Qué queremos estudiar?**

## Difusión

Proceso estocástico donde una entidad se difunde típicamente de un lugar de mayor concentración hacia uno de menos.

¿Cómo evoluciona una densidad inicial de partículas a lo largo del tiempo?

Ejemplo visual difusión de tinturas

La formulación del proceso de difusión involucra resolver la ecuación diferencial

$$\frac{du(x, t)}{dt} = \alpha \frac{d^2 u(x, t)}{dx^2}$$

Obs: Wild Laplacian operator appears!

## Algo de intuición: Caminatas aleatorias

Podemos simular la trayectoria individuales de muchas partículas que parten desde el mismo punto inicial  $x_0$  y su posición en tiempo  $k$  está dada por:

$$x_k = x_{k-1} + e$$

siendo  $e$  un variable aleatoria que toma valores -1 o 1.

## Gráficamente




Figure: Caminata aleatoria para 20 partículas durante 500 pasos

## Distribución final (1000 partículas)





Figure: Distribución al cabo de 500 pasos para 1000 partículas

Otra forma de verlo, [Dalton board](#)


## Modelo de caminata aleatoria

$P^t(x)$  la probabilidad que una partícula esté en la posición  $x$  en tiempo  $t$






## Modelo de caminata aleatoria



## Modelo de caminata aleatoria



## Modelo de caminata aleatoria

$$P^{t+1}(x) = \alpha P^t(x-1) + (1-2\alpha)P^t(x) + \alpha P^t(x+1)$$

$$P^{t+1}(x) = P^t(x) + \alpha(P^t(x-1) - 2P^t(x) + P^t(x+1))$$

$$P^{t+1}(x) - P^t(x) = \alpha(P^t(x-1) - 2P^t(x) + P^t(x+1))$$

Llamando  $u$  al vector que discretiza  $P$ , queda

### Ecuación de difusión discretizada

$$u_i^{(t+1)} - u_i^{(t)} = \alpha(u_{i-1}^{(t)} - 2u_i^{(t)} + u_{i+1}^{(t)})$$

El Laplaciano strikes back

## Ejemplo

Discretizamos con 100 valores el rango  $[0,100]$ ,  $u_0$  es uniforme en  $[40,60]$  y nula en el resto.




Figure: Evolución de  $u$  durante 300 pasos. Atención a la distribución final.

## Mismo ejemplo

